Resumen del video IDO

A lo largo de la exposición el ponente aclara que el aprendizaje automático es en esencia estadística aplicada potenciada por la capacidad de cómputo actual e inicia la narrativa planteando el reto fundamental de medir el tiempo hasta la ocurrencia de un evento en situaciones del mundo real donde los datos no siempre están completos.

Al intentar analizar sucesos como el fallecimiento de un paciente o la falla de un sistema nos encontramos constantemente con el fenómeno de la censura de datos la cual ocurre por la derecha cuando el estudio termina o la persona abandona el seguimiento antes de que el evento suceda y por la izquierda cuando la persona ingresa al estudio con una condición previa cuya fecha de inicio exacta se ignora. Para evitar sesgar los resultados al descartar esta información o asumir de forma forzada una distribución matemática continua la charla se adentra en el enfoque no paramétrico mediante el estimador de Kaplan-Meier el cual permite construir paso a paso y de forma escalonada la curva de probabilidad de supervivencia apoyándose en la Ley de los Grandes Números y en la estimación por máxima verosimilitud.

A medida que la presentación avanza la historia traslada su atención hacia la práctica y la programación mostrando cómo Python se ha convertido en la herramienta clave para automatizar estos procesos actuariales. El ponente recalca la importancia de consultar las documentaciones oficiales y muestra la aplicación de librerías especializadas como Lifelines para el ajuste rápido de curvas y visualizaciones de funciones de azar junto con sus intervalos de confianza así como la librería scikit-survival la cual extiende el ecosistema de scikit-learn para permitir la implementación de modelos predictivos avanzados como bosques aleatorios y regresiones de Cox.

En el tramo final de la exposición se sigue el flujo de trabajo práctico sobre un conjunto de datos médicos empezando por la limpieza de variables en arreglos de Pandas pasando por la división aleatoria de los datos en conjuntos de entrenamiento y prueba para medir la capacidad de predicción del algoritmo y concluyendo con la aplicación del test de Log-Rank una prueba de hipótesis fundamentada en una distribución Chi-cuadrada que determina si las diferencias observadas entre las curvas de supervivencia de distintos grupos o tratamientos son estadísticamente significativas o simplemente fruto del azar.